

วิเคราะห์ระบบจริง (White Box) ตามเกณฑ์ Data Engineering ข้อ 2-6

วิเคราะห์จากโค้ดของ repo C:\ETL (branch new-optimizer) ไม่ใช่จากเอกสาร/README ไม่ได้ให้คะแนนตัวเอง — เอกสารนี้ตอบเพียงว่า "ระบบทำอะไรจริง ทำอย่างไร อยู่ที่ไหน"

วิธีการและข้อจำกัด (อ่านก่อน)

- อ่านโค้ดแบบ static ทั้งหมด ไม่ได้รันระบบ ไม่ได้รัน test — พฤติกรรมตอนรันจึงเป็นการอนุมานจากโค้ด
- แบ่งงานให้ 4 agent อ่านโค้ดคู่ขนาน (Extraction / Transformation / Loading / Utilization) แล้วรวมผล ผู้เขียนตรวจโค้ดตัวเองเฉพาะข้อที่ใช้อ้างบอยหรือนำประหลาดใจ ได้แก่ assembly.py:43-45 (total = clean + quarantine), cleansing.py:29-39 (ลบซ้ำไม่นับ), whitebox.py:1593-1611 (ingest-source จำลอง, Ingestion.jsx:831,868, spark_quality_engine.py:1702-1788 (ลำดับเขียน/คิดคะแนน/trigger Gold), analytics.py:768-806 (Sell-In/Out mock), และการไม่มี dashboard ใน infra/grafana/provisioning/ ข้อที่เหลืออ้างตาม agent พร้อม path:line ให้ย้อนตรวจได้
- สถานะที่ใช้: REAL = มีโค้ดและเชื่อมต่อทำงานจริง · PARTIAL = มีบางส่วน/มีข้อจำกัดสำคัญ · UI ONLY = มีหน้าจอ/ข้อความแต่ไม่มี logic จรจรงรับ · MOCK = ข้อมูลจำลอง/ฮาร์ดโค้ด · NOT FOUND = ไม่พบในโค้ด
- ตัวย่อ: SQE = services/spark/spark_quality_engine.py · S/ = services/spark/sdoqap/ · API/ = services/api/app/api/ · RC = services/spark/rules_config.json
- ผู้กำหนด logic: Dev (hard-code โดยนักพัฒนา) · User (ผู้ใช้/วิศวกรตั้งค่า) · System (ระบบตรวจจับ/อนุมานเอง) · LLM (โมเดลเสนอ)

0. ตารางภาพรวม

หัวข้อ	สิ่งที่ระบบทำจริง	สถานะ	ไฟล์/Function สำคัญ
2. กระบวนการ	Spark pipeline 21 stage ใน 3 ช่วง (ALIGN 1 · TRANSFORM 12 · POST_LOAD 8) + ขั้นตอน inline (lock, อ่าน raw, เขียน quarantine, MERGE, OPTIMIZE/VACUUM, archive, trigger Gold) + กระบวนการนอก stage (landing/checksum ที่ API, auto-remediation, semantic auto-learn, rule governance, profile drift, Gold layer)	REAL	S/pipeline/plan.py, registry.py, SQE:run_quality_check (1551-1811), API/pipeline.py:271-303
3. Extraction	รับข้อมูล 3 แบบที่ต่อครบจริง: อัปโหลดไฟล์ CSV/Excel, REST API (fetch ฝั่ง API), PostgreSQL → แปลงเป็น CSV → เขียน raw ลง HDFS ต่อ 1 ingest + บันทึก run ใน ES; Reddit→Kafka→Spark Streaming มีจริงแต่แยกเส้น ไม่เข้า quality engine	REAL (3 แหล่ง) / PARTIAL (stream) / UI ONLY (แทบ API และ Stream บนหน้า Ingestion)	API/pipeline.py (ingest_csv/api/rdbms, land_and_queue), API/ingest_guards.py, streaming_job.py
4. Transformation	แปลงชนิดข้อมูล, rename คอลัมน์แบบ fuzzy, ลบซ้ำตาม PK, validate (null/type/date) แล้วแยก valid/invalid, มาตรฐานวันที่ (รวม พ.ศ.→ค.ศ.), range/IQR/Z-score → quarantine, semantic standardize, DSL remediation (fillna/calculate/cast/filter)	REAL (หลัก) / PARTIAL (imputation, join, aggregation บนข้อมูลธุรกิจ)	S/stages/schema.py, cleansing.py, standardize.py, rules.py, anomaly.py, SQE:819-1220
5. Loading	เขียน Delta: quarantine (append, ลบตาม ingest_id ก่อน) แล้ว MERGE เข้า active ตาม PK; metadata/metrics/lineage ลง Elasticsearch; raw → archive	REAL (Delta MERGE) / NOT FOUND (quality gate ก่อนโหลด ระดับตาราง, ตรวจสอบ source vs ปลายทาง, ES bulk, incremental/CDC, rollback)	SQE:1702-1805, S/stages/assembly.py, report.py
6. Utilization	Create Dashboard (AI) ใช้งานได้จริงตั้งแต่เลือก dataset → LLM ออกแบบ spec → pandas คำนวณ → บันทึก; หน้า Dashboard/Analytics/Export/Trust-check ใช้ข้อมูลจาก ES และ Delta จริงบางส่วน ปั่นกับส่วน MOCK	REAL (Builder, Trust-check, Export) / PARTIAL (Dashboard, Analytics, Alert) / MOCK (Sell-In/Out) / NOT FOUND (Grafana dashboard, Prometheus ที่รันจริง)	API/dashboards.py, dashboard_llm.py, dashboard_compute.py, API/analytics.py, API/lineage.py

ข้อสังเกตเด่น 5 ข้อ (ละเอียดในแต่ละหัวข้อ):

- ยอดรวม total_records คำนวณจาก clean + quarantine เสมอ จึง "ลงตัว" โดยโครงสร้าง ไม่ได้เทียบกับจำนวนแถวต้นทาง และแถวที่ถูกลบซ้ำใน auto_clean ไม่อยู่ในทั้งสองฝั่ง (บันทึกเป็นข้อความ resolved_N_duplicates เท่านั้น)
- คะแนนคุณภาพ (quality_score) ถูกคำนวณ หลัง เขียน Delta แล้ว → ไม่ได้ขบวนการโหลด ใช้ส่งแจ้งเตือน / ตัดป้าย warnings / ตัดสินว่าจะ rebuild Gold
- แทบ "API" และ "Stream" บนหน้า Ingestion เป็นการจำลอง ("simulated": True) ส่วนช่องทาง REST API จริงเรียกได้ทาง API ตรง, n8n หรือ test_data_source.bat
- Grafana มีแค่ datasource + alert rules ไม่มี dashboard และไม่มี Prometheus รันอยู่ใน compose

ข้อ 2 — จำนวนกระบวนการในการจัดการข้อมูล

2.1 โครงสร้างการทำงานจริง

ลำดับกำหนดใน S/pipeline/plan.py:2-6 และลงทะเบียนด้วย decorator ใน registry.py:17-21 (วันที่ละ stage และจับเวลาลง stage_seconds — registry.py:24-32) ลำดับจริงของงานหนึ่งรอบอยู่ที่ SQE:run_quality_check (1551-1811):

```
ไหลตกฏ → อ่าน raw (ทุกคอลัมน์เป็น string) → guard ไฟล์ว่าง/long-text
→ ALIGN: schema_align
→ TRANSFORM: schema_drift → auto_clean → validation → dedup → standardize_dates → standardize_categories
               → range_rules → anomaly_iqr → anomaly_zscore → anomaly_induced → quarantine_assembly → column_filter
→ (inline) เขียน quarantine Delta → MERGE เข้า active Delta → OPTIMIZE/VACUUM ทุก N เวิร์กชัน
→ POST_LOAD: distribution → quarantine_breakdown → copdq → freshness → quality_score
               → ai_advisory → operational_impact → report
→ (inline) ถ้า score ≥ threshold สั่ง rebuild Gold → archive raw → ปลอม lock
```

2.2 ตาราง 21 stage ตามลำดับรัน

#	Stage	หน้าที่ / ทำงานอย่างไร	Input	Output	ไฟล์ : function	ใครกำหนด logic	อัตโนมัติ?
1	schema_align	ล้างชื่อคอลัมน์, สร้าง row_hash (md5), rename แบบ fuzzy ให้ตรงชื่อใน registry, promote Integer→Double ถ้ามีทศนิยม, cast ตามชนิด (Integer/Double/Timestamp 6 รูปแบบ + epoch), repartition(10)	DF string + spec	DF ที่ cast แล้ว	S/stages/schema.py:10-98	Dev (อัลกอริทึม) + System (spec อนุมานจากข้อมูลถ้าเป็น ตารางใหม่ SQE:1840-1925)	อัตโนมัติ
2	schema_drift	เทียบกับ spec: คอลัมน์หาย→เติม NULL+alert, ชนิดไม่ตรง→cast เป็น string, คอลัมน์ใหม่→เพิ่มใน spec; บันทึก sdoqap_schema_drifts / sdoqap_schema_proposals	DF + spec + rules.schema_evolution	DF + drift record	schema.py:101-243	Dev (gate) + User (policy; คอนอุมัติผ่าน API/schema.py:63-183)	อัตโนมัติ
3	auto_clean	(ถ้า auto_clean=true ค่าเริ่มต้น) apply DSL remediation → dropDuplicates ตาม PK (แถว PK ว่างถูกแยกไว้ไป quarantine)	DF	DF ลบซ้ำแล้ว	S/stages/cleansing.py:6-44	Dev (ลบซ้ำ) + User/LLM (DSL)	อัตโนมัติ
4	validation	ตั้ง flag รายแถว: missing_primary_key, null_value_in_<col>, invalid_type_<col>, missing_date แล้วแยก valid_df / invalid_df	DF	valid + invalid	cleansing.py:47-115	Dev (rule ฮาร์ดโค้ด)	อัตโนมัติ
5	dedup	dropDuplicates ตาม PK บน valid; แถวที่ถูกตัดไป quarantine เหตุผล duplicate_records	valid_df	clean_df + duplicate_df	cleansing.py:118-138	Dev	อัตโนมัติ (ปกติว่างเมื่อ auto_clean เปิด)
6	standardize_dates	UDF กับคอลัมน์ชื่อ วันที่ / date / Date เท่านั้น รองรับ d Mon yyyy, d-m-yyyy, yyyy-m-d, ปี > 2500 ลว 543 → YYYY-MM-DD	clean_df	วันที่เป็นมาตรฐาน	S/stages/standardize.py:6-57	Dev	อัตโนมัติ

#	Stage	หน้าที่ / ทำงานอย่างไร	Input	Output	ไฟล์ : function	ใครกำหนด logic	อัตโนมัติ?
7	standardize_categories	map คำหลัก→หมวด จาก <code>standardization_rules</code> ใน registry	clean_df	คอลัมน์ถูกแทนที่	<code>standardize.py:60-103</code>	User (rule เป็นข้อมูล)	อัตโนมัติ — แต่ไม่พบที่ใดใน repo เขียน <code>standardization_rules</code> จึงเกือบไม่ถูกใช้
8	range_rules	ค่า < min หรือ > max ตาม <code>range_checks</code> → quarantine <code>out_of_range_<col></code>	clean_df	clean + range-violation	<code>S/stages/rules.py:15-33</code>	User (<code>range_checks</code> ; มีแค่ <code>student_course_scores</code> , RC:530-539)	อัตโนมัติ
9	anomaly_iqr	รันเมื่อ <code>value_range.mode</code> เป็น auto/adaptive: fence = Q1-k*IQR, Q3+k*IQR (k ค่าเริ่มต้น 1.5) ทุก คอลัมน์ตัวเลข → quarantine	clean_df	clean + outlier	<code>S/stages/anomaly.py:6-44</code> ; <code>dynamic_rules_engine.py:185-242</code>	Dev (อัลกอริทึม) + User (mode,k) + System (ขอบเขต)	อัตโนมัติ
10	anomaly_zscore	$abs(x-mean)/std > 3.0$ (ฮาร์ดโค้ด ไม่มีสวิตช์) ซ้ำม คอลัมน์ variance 0	clean_df	clean + outlier	<code>anomaly.py:47-75</code>	Dev	อัตโนมัติ
11	anomaly_induced	OR เงื่อนไข SQL จาก <code>rules.induced.*.condition</code> (กฎจาก decision tree ที่คนอนุมัติ)	clean_df	clean + match	<code>anomaly.py:78-118</code>	LLM/ML เสนอ + คนอนุมัติ	อัตโนมัติ (มีกว้าง)
12	quarantine_assembly	union quarantine ทุกประเภท + <code>run_id</code> , <code>rejected_at</code> ; นับ clean/quarantine; <code>total = clean + quarantine</code>	DFs ข้างบน	counts	<code>S/stages/assembly.py:6-49</code> (total บรรทัด 45)	Dev	อัตโนมัติ
13	column_filter	ตัดคอลัมน์ที่ไม่อยู่ใน <code>schema_spec</code>	clean_df	clean_df แคลลง	<code>assembly.py:52-75</code>	Dev + spec	อัตโนมัติ
14	distribution	สัดส่วนคลาส (ชื่อคอลัมน์ที่รู้จัก 11 ชื่อ หรือคอลัมน์ string 2-25 คำ)	active Delta	class_balance	<code>S/stages/metrics.py:8-59</code>	Dev + System	อัตโนมัติ
15	quarantine_breakdown	group by <code>reject_reason</code>	quarantine (run นี้)	<code>{reason: count}</code>	<code>metrics.py:62-91</code>	Dev	อัตโนมัติ
16	copdq	รวมมูลค่าคอลัมน์การเงิน (ชื่อ <code>total_sales/sales/revenue/profit/price/amount/total</code>) ของแถวที่ถูก quarantine	quarantine	<code>quarantined_financial_value</code>	<code>metrics.py:94-116</code>	Dev	อัตโนมัติ
17	freshness	<code>now - max(date)</code> เป็นชั่วโมงของแถว active รอบนี้	active	<code>max_lag_hours</code>	<code>metrics.py:119-158</code>	Dev	อัตโนมัติ
18	quality_score	<code>clean/total×100</code> ; alert ถ้าต่ำกว่า threshold; Z-score ของอัตรา quarantine เทียบประวัติ (ต้องมี ≥ 3 รอบ)	counts + ประวัติจาก ES	score, z, is_anomaly	<code>metrics.py:161-213</code>	Dev (สูตร) + User/System (threshold)	อัตโนมัติ
19	ai_advisory	วิเคราะห์ profile drift (PSI) → ให้ LLM (Grok→Ollama→heuristic) เสนอกฎ → เก็บเป็น PROPOSED ใน ES; ฝึก decision tree หา rule	metrics + ตัวอย่าง quarantine	proposal	<code>S/stages/advisory.py:6-167</code>	LLM/ML เสนอ + คนอนุมัติ	อัตโนมัติ (<code>ai_advisor.enabled=true</code> , <code>trigger="always"</code> ใน RC:42-48)
20	operational_impact	คะแนนผลกระทบถ่วงน้ำหนักต่อแถวที่ล้มเหลว	quarantine + <code>column_weights</code>	<code>operational_impact_score</code>	<code>metrics.py:216-261</code>	Dev (น้ำหนัก User ปรับได้)	อัตโนมัติ
21	report	เขียน <code>sdoqap_quality_runs</code> , <code>sdoqap_lineage_runs</code> , <code>sdoqap_pipeline_runs</code>	ctx	เอกสารใน ES	<code>S/stages/report.py:52-80</code>	Dev	อัตโนมัติ

2.3 กระบวนการที่ยู่นอกรายการ stage

กระบวนการ	ทำอะไร	ไฟล์	ผู้เริ่ม
รับเข้า + normalize	Excel→CSV (pandas), JSON/API→CSV (รวม key ทั้งหมดเรียงตัวอักษร, nested เก็บเป็น JSON string), RDBMS→CSV	API/pipeline.py:327, 465-508, 577-610	User
ตรวจไฟล์ซ้ำ (checksum)	SHA-256 + ค้นใน sdoqap_runs ; ซ้ำที่สถานะ QUEUED/RUNNING/SUCCEEDED จะไม่รับซ้ำ	API/pipeline.py:272-284, run_registry.py:21-47	อัตโนมัติ
ตรวจคอส์มัน PK ในหัวไฟล์	ถ้ามี PK ลงทะเบียนแล้วแต่ไฟล์ขาด → HTTP 400	pipeline.py:250-259	อัตโนมัติ
อนุมาน schema + PK ตารางใหม่	inferSchema , สแกนหา leading zero (บังคับเป็น string), หา PK ที่ไม่ซ้ำ ≥ 90%, สারণ row_hash	SQE:1840-1925 , S/common/keys.py:14-55	อัตโนมัติ
สร้างกฎเริ่มต้น	generate_rules_from_schema เขียนกฎลง rules_config.json	dynamic_rules_engine.py:660-731	อัตโนมัติ
คิวงาน + lock	1 งาน/ตาราง (FIFO ในหน่วยความจำ) + lock ใน ES พร้อม heartbeat	trigger_core.py:53-82, SQE:126-218	อัตโนมัติ
Auto-remediation (LLM)	เมื่อมี quarantine > 0 daemon เรียกให้ LLM สร้างกฎ DSL เก็บกฎที่ confidence ≥ 0.80 เขียนลง registry แล้วรันซ้ำ	spark_trigger_daemon.py:137-179, auto_remediation_engine.py	อัตโนมัติ (ไม่ต้องคนอนุมัติ)
Semantic auto-learn	คะแนนความเหมือน 0.90-1.0 เขียน mapping memory เอง; 0.60-0.90 ส่งคนรีวิว	SQE:687-817	อัตโนมัติ + คนรีวิว
Governance ของกฎ	audit log + สারণ 10 เวอร์ชัน + rollback; อนุมัติ AI proposal ผ่าน guardrail (พื้น 70, ลดได้ ≤ 10%)	API/dynamic_rules.py:99-192, 472-636	User
Profile store	EMA ต่อคอส์มัน, PSI drift (เดือน 0.1 / วิกฤต 0.25)	data_profile_store.py	อัตโนมัติ
Gold layer	รวมสถิติจาก metadata ของ run ใน ES (ไม่ใช่ข้อมูลธุรกิจ) เขียน 4 index	spark_gold_layer.py:184-430	อัตโนมัติหลังรันผ่าน / ปุ่ม rebuild
Archive raw	ย้าย raw ไป /data/archive/<table>/<ingest_id>	SQE:1790-1805	อัตโนมัติ
Streaming (Reddit)	Kafka → Parquet + ES แยกเส้น	streaming_job.py	User
Whitebox module	pandas pipeline ใน API process ผูกกับชุดข้อมูลคะแนนนักเรียน	API/whitebox.py	User

สรุปจำนวน: ใน Spark pipeline มี **21 stage ที่ลงทะเบียน** (1 + 12 + 8) และมีขั้นตอน inline อีก 7 (lock, อ่าน raw, เขียน quarantine, MERGE, OPTIMIZE/VACUUM, trigger Gold, archive) นอกจากนี้ยังมีกระบวนการฝั่ง API/daemon อีกอย่างน้อย 10 รายการตามตารางด้านบน ผู้อ่านควรระบุให้ชัดว่านับ "stage ใน pipeline" หรือนับ "กระบวนการทั้งระบบ" เพราะตัวเลขต่างกัน บาง stage ทำงานแต่ผลน้อยหรือแทบไม่ถูกใช้ (เช่น standardize_categories , anomaly_induced)

ข้อ 3 — Data Extraction

3.1 แหล่งข้อมูลที่ระบบรองรับจริง

แหล่ง	จุดเข้า	รูปแบบที่จัดการ	สถานะ
ไฟล์ CSV (อัปโหลด)	POST /api/v1/pipeline/ingest/csv — API/pipeline.py:315-333 (ingest_csv); UI แห็บ "ไฟล์" Ingestion.jsx:213-313	เขียน bytes ลง HDFS ตามที่ได้รับ ชื่อ <table>.csv	REAL
Excel .xlsx/.xls	route เดียวกัน pipeline.py:324-329	pd.read_excel(...).to_csv() (อ่านเฉพาะ sheet แรก)	REAL
REST API → JSON/CSV	POST /ingest/api — pipeline.py:335-508; relay ผ่าน n8n webhook (ingestion_workflow.json:48-72); test_data_source.bat:109-135	JSON (list / result.records / records / data / items / dict เดี่ยว) หรือ CSV; มี resolver data.go.th (CKAN)	REAL ที่ฝั่ง API/n8n · UI ONLY บนแห็บ "API" ของหน้า Ingestion
PostgreSQL	POST /ingest/rdbms — pipeline.py:567-613; UI แห็บ "ฐานข้อมูล" Ingestion.jsx:233-274	db_type ต้องเป็น postgresql	REAL (เปิดใช้เมื่อตั้ง RDBMS_ALLOWED_HOSTS)
n8n schedule ทุก 30 นาที	infra/n8n/ingestion_workflow.json:8-17	Olist CSV, data.go.th limit=10000, SELECT * FROM sales_records — แหล่งตายตัว	REAL แต่เป็นแหล่งเดโมฮาร์ดโค้ด

แหล่ง	จุดเข้า	รูปแบบที่จัดการ	สถานะ
Reddit → Kafka → Spark Streaming	POST /ingest/reddit → daemon /stream/start → reddit_stream.py, streaming_job.py	โพสต์ Reddit	PARTIAL: ข้อมูลลงจริงแต่ ไม่เชื่อมกับ quality engine
JSON/Parquet/Avro/XML (ไฟล์)	มีไฟล์ตัวอย่างใน data/samples/formats/ แต่ไม่มี code ที่อ่าน	—	NOT FOUND
MySQL/Oracle/Mongo/JDBC	ถูกปฏิเสธ HTTP 400 (pipeline.py:586-587)	—	NOT FOUND

เห็น **"API"** และ **"Stream"** บนหน้า **Ingestion** เป็นของจำลอง: ปุ่มเรียก handleConnectSourceAndProfile (Ingestion.jsx:831, 868) → POST /whitebox/ingest-source ซึ่ง whitebox.py:1593-1618 ไม่ได้เชื่อมต่อแหล่งใดจริง ตอบ "simulated": True และแสดงป้าย "โมดจำลอง" (Ingestion.jsx:179-181) ฟังก์ชันที่ทำงานจริง (handleApiSubmit :568, handleCsvSubmit :530, handleRdbmsSubmit :628) ถูกประกาศไว้ แต่ไม่พบ JSX ที่เรียกใช้ ช่องกรอก broker/topic/group ของ Kafka ไม่มีผลต่อการทำงานจริง (broker หารัดโค้ดใน reddit_stream.py:39-43, streaming_job.py:9)

3.2 ขั้นตอนการรับข้อมูล

อัปโหลดไฟล์ (pipeline.py:315-303, land_and_queue 271-303):

- 1. ยืนยันตัวตน (session cookie หรือ X-Service-Key) — auth.py:88-102
- 2. ตรวจสอบชื่อตาราง regex ^[A-Za-z0-9_-]{1,128}\$ — validation.py:4-18
- 3. จำกัดขนาด 200 MB (ค่าเริ่มต้น MAX_UPLOAD_MB) เกิน → HTTP 413 — ingest_guards.py:96-109
- 4. ไฟล์ว่าง → HTTP 400; Excel → แปลงเป็น CSV
- 5. คำนวณ SHA-256, ตรวจสอบไฟล์ซ้ำ, ตรวจสอบคีย์ PK ในหัวไฟล์
- 6. เขียน raw ลง HDFS ผ่าน WebHDFS: /data/raw/<table>/<ingest_id>/<table>.csv (retry 5 ครั้ง ห่าง 3 วินาที — pipeline.py:194-227)
- 7. สร้างเอกสาร run ใน ES sdoqap_runs สถานะ QUEUED (run_registry.py:50-65)
- 8. เรียก Spark trigger daemon /retry (pipeline.py:230-242) → รัน spark-submit ต่อ

REST API: SSRF guard (host ต้องเป็น data.go.th หรืออยู่ใน API_INGEST_ALLOWED_HOSTS, **ปิดโดยค่าเริ่มต้น** ถ้าไม่ตั้ง), GET เดียว timeout 15 วินาที, redirect ≤ 3 ครั้งพร้อมตรวจสอบ host ใหม่ (ingest_guards.py:22-51) → parse JSON/CSV → flatten เป็น CSV (pipeline.py:481-503) **ไม่มี pagination และไม่มี retry** ในฝั่ง API (n8n มี retry 3 ครั้งและส่ง limit=10000)

PostgreSQL: host ต้องอยู่ใน allowlist, อนุญาตเฉพาะ SELECT (ห้าม ;), session read-only, statement_timeout 30 วินาที, เกิน RDBMS_MAX_ROWS (1,000,000) → 413 (ingest_guards.py:54-93) → เขียน CSV (NULL กับ string ว่างกลายเป็นช่องว่างเหมือนกัน)

อ่านที่ Spark: csv(header=true, multiLine=true, escape=", quote=") อ่านทุกคอลัมน์เป็น string (SQE:1643-1644) **ไม่มีการตรวจสอบ delimiter/encoding** — ใช้ comma และ UTF-8 ตามค่าเริ่มต้นของ Spark ไฟล์ที่ไม่ใช่ UTF-8 (เช่น cp874) จะไม่ถูกตรวจสอบหรือแปลง ข้อมูลจาก Excel/API ถูก normalize เป็น UTF-8 ก่อนลง HDFS

3.3 สิ่งที่ต้องตรวจสอบก่อนข้อมูลเข้า pipeline

รายการตรวจสอบ	เงื่อนไขจริง	อยู่ที่	สถานะ
ชื่อตาราง (path traversal)	regex ข้างบน	validation.py:4-18	REAL
ขนาดไฟล์	≤ 200 MB	ingest_guards.py:96-109	REAL (ใช้กับ /ingest/csv; /whitebox/upload-csv ไม่จำกัด)
ไฟล์ว่าง	0 byte → 400; ที่ Spark: 0 คอลัมน์/0 แถว → exit 75 → SKIPPED	pipeline.py:322, SQE:1670-1674	REAL
นามสกุล/MIME/โครงสร้าง CSV	ไม่มี (ไฟล์ใดก็ได้ผ่าน)	—	NOT FOUND

รายการตรวจ	เงื่อนไขจริง	อยู่ที่	สถานะ
คอสมัน PK ในหัวไฟล์	ตรวจเมื่อมี PK ลงทะเบียนแล้ว	pipeline.py:250-259	PARTIAL (ไม่ตรวจคอสมันอื่น)
Schema / ชนิด / Null	ตรวจ หลัง landing ที่ Spark ระดับแถว	schema.py , cleansing.py	REAL (หลังลงไฟล์)
ไฟล์ซ้ำ (checksum)	SHA-256 + สถานะ QUEUED/RUNNING/SUCCEEDED	run_registry.py:21-47	REAL (มีช่อง race; n8n ช้ามาการตรวจนี้)
จำนวน record ต้นทาง vs ที่รับ	ไม่มี (บันทึกเพียง size_bytes ; rows_ingested มีเฉพาะ response ของ RDBMS)	—	NOT FOUND
Checksum หลังเขียน HDFS	ไม่มีการอ่านกลับตรวจ	—	NOT FOUND
Long-text CSV guard	เตือนเมื่อค่าเฉลี่ยความยาว > 150 ตัวอักษร บล็อกได้เฉพาะเมื่อ strict_csv_guard ซึ่งไม่มีใครตั้ง และเงื่อนไข "csv" in raw_path เป็นจริงเฉพาะเมื่อชื่อตารางมีคำว่า csv	SQE:1646-1668	PARTIAL (แทบไม่ทำงาน)

3.4 การเก็บ raw และ metadata

- **Raw:** /data/raw/<table>/<ingest_id>/<table>.csv → หลังรันสำเร็จย้ายไป /data/archive/<table>/<ingest_id> (SQE:1790-1805) เส้นทางเก่า (n8n/test_data_source.bat) เขียนแบบแบน /data/raw/<table>/<table>.csv และ **ลบ raw** **ทั้งเมื่อไม่มี quarantine** (SQE:1798-1803) มี retention ลบของเก่า > 30 วันใน /data/raw และ /data/quarantine (scripts/ops/data_retention_cleanup.py) แต่ไม่แตะ archive
- **Metadata** **ต่อ ingest** (sdoqap_runs, _id = ingest_id): table_name, checksum, source (file|api|rdbms), size_bytes, raw_path, state + daemon เพิ่ม started_at, finished_at, exit_code, error สถานะ: QUEUED → RUNNING → SUCCEEDED / FAILED / SKIPPED / TRIGGER_FAILED
- **เส้นทาง n8n** แบบเก่าไม่มี ingest_id จึงไม่มีเอกสารใน sdoqap_runs
- **Run id** **ตอนประมวลผล:** run_YYYYmmdd_HHMMSS_ffffff (SQE:1564) ปรากฏใน quality/lineage/pipeline docs และคอสมัน run_id ของ active/quarantine

3.5 เมื่อ extraction ผิดพลาด

เหตุการณ์	การจัดการ
เกิน limit / ไฟล์ว่าง / Excel เสีย / ชื่อผิด / PK ซ้ำ	HTTP 413/400 ทันที ไม่ลงไฟล์
ไฟล์ซ้ำ	ตอบ 200 status:"duplicate" พร้อม ingest_id เดิม
REST: host/redirect ไม่ผ่าน, ไม่ใช่ 200, parse ไม่ได้, ว่าง	HTTP 400 ไม่ retry ไม่ alert
WebHDFS เขียนล้มเหลว	retry 5 ครั้งแล้ว HTTP 500 (ยังไม่มีการเอกสาร run)
Daemon ติดต่อไม่ได้	HTTP 503, run = TRIGGER_FAILED, raw ยังอยู่, กู้ด้วย POST /pipeline/retry/<ingest_id>
Spark อ่าน/แปลงล้มเหลว	เขียน sdoqap_pipeline_runs {state:"failed", error_msg}, ปลอม lock, exit 1 → run = FAILED; raw ไม่ถูก archive จึงรันซ้ำได้
แถวเสียระดับแถว	quarantine พร้อม reject_reason ใน Delta /data/quarantine/<table>
แจ้งเตือน	schema drift ส่ง alert; ไม่พบ alert เฉพาะสำหรับรันที่ failed/skipped (ดูสถานะได้จาก API GET /pipeline/runs/<id> และ UI)

3.6 เส้นทาง Streaming

POST /ingest/reddit → daemon เปิด reddit_stream.py (PRAW ถ้ามี credential, ไม่เช่นนั้น RSS; สำรองสุดท้ายคือโพสต์จำลอง sim...) → Kafka topic reddit_raw → streaming_job.py (Spark Structured Streaming, startingOffsets=earliest, failOnDataLoss=false) → Parquet /data/reddit/parquet (partition ตาม subreddit) + ES index reddit (ไม่กำหนด doc id) **ไม่มี validation / dedup / quarantine / run registry** และไม่พบการอ้างถึง /data/reddit ใน spark_quality_engine.py (grep reddit ใน engine ไม่พบ) — จึงไม่เชื่อมกับ pipeline คุณภาพ งานจำกัดเวลาโดย daemon (ค่าเริ่มต้น 40 วินาที) ป้าย "Ingesting" ของ Kafka บนหน้า Home เป็นการเช็ค TCP port kafka:9092 ไม่ใช่การเช็คว่ามีข้อมูลไหล (system.py:42-84)

3.7 Workflow จริง (เฉพาะขั้นตอนที่พบในโค้ด)

```
[File/API/Postgres]
User (UI/API/n8n) → API: ตรวจ auth·ชื่อตาราง·ขนาด·ว่าง·SSRF/SQL guard·checksum·PK header (Dev rules)
                  → API: แปลง Excel/JSON/DB → CSV
                  → API: เขียน raw → HDFS /data/raw/<table>/<ingest_id>/ (retry 5)
                  → API: สร้าง sdoqap_runs (QUEUED)
                  → API → Spark daemon /retry → spark-submit → (ต่อข้อ 4)

[n8n schedule ทุก 30 นาที] แหล่งตายตัว → n8n เขียน HDFS ตรง (เส้นแบน, ไม่มี ingest_id) → daemon /retry

[Reddit stream] User → API → daemon → Kafka → Spark Streaming → Parquet + ES (จบ ไม่เข้า quality engine)
```

LLM ไม่เกี่ยวข้องกับการ extraction

ข้อ 4 — Data Transformation

4.1 Transformation ที่มีจริง (พร้อม Before → Logic → After)

ตัวอย่างที่มีเครื่องหมาย (T) มาจาก unit test ใน services/spark/tests/unit/; (D) มาจากไฟล์ตัวอย่างใน repo ทั้งหมด ยังไม่ได้รันซ้ำ After ที่ระบุเป็นผลที่อ่านได้จาก logic/test

(1) แปลงชนิดข้อมูล — REAL

- **Before (T test_stage_schema.py:6-14):** spec {student_id: String, score: Integer, updated_at: Timestamp}, แกว ("S1", "1,234", "2026-09-15 14:00:00")
- **Logic (schema.py:64-93):** Integer = ตัดอีกขระที่ไม่ใช่ [\d-] แล้ว cast double→int; Double = ตัดที่ไม่ใช่ [\d.-]; Timestamp = coalesce 6 รูปแบบ + epoch ms/sec
- **After:** score = 1234, updated_at เป็น Timestamp
- **Promotion (T test_stage_schema.py:17-21):** "12.50", "3" ในคอลัมน์ Integer → Double 12.5, 3.0
- **ผู้กำหนด:** spec มาจาก registry หรือ inferSchema · อัตโนมัติ (stage 1)
- **ข้อควรระวังจากโค้ด (ไม่ได้รัน):** regex ของ Integer ตัด "." ทั้ง ดังนั้น "12.00" จะกลายเป็น 1200 ขณะที่เงื่อนไข promote \.[0-9]*[1-9]+ ไม่จับ ".00" ทั้งที่คอมเมนต์ schema.py:67 ระบุว่าจัดการได้ ชนิดอื่นนอกจาก Integer/Double/Timestamp ไม่ถูก cast

(2) Rename / mapping คอลัมน์ — REAL (heuristic)

- **Before (T):** หัวคอลัมน์ "Student ID" → clean_column_name ได้ Student_ID → normalize_name = studentid ตรงกับ student_id ใน registry
- **After:** คอลัมน์ student_id (พิมพ์ [RENAME] ใน log) — schema.py:28-35, names.py:4-15
- ไม่พบ rename map ที่ผู้ใช้กำหนดเอง (มีเฉพาะใน whitebox: studentId→student_id, fullName→student_name whitebox.py:1103-1105)

(3) ลบข้อมูลซ้ำ — REAL (มีข้อจำกัด)

- **Logic:** 2 ขั้นตอนตาม PK — auto_clean (cleansing.py:29-39) แล้ว dedup (cleansing.py:118-138)
- **Test:** test_stage_cleansing.py:8-12 (3 แกว → 2 แกว) และ :31-37
- **ข้อจำกัดที่ยื่นจากโค้ด:** แกวที่ auto_clean ลบ ไม่ถูกส่ง quarantine และไม่ถูกนับใน total (เหลือแค่ข้อความ resolved_N_duplicates); orderBy(date desc) ตามด้วย dropDuplicates ไม่รับประกันว่า "แถวล่าสุด" จะอยู่รอด (คอมเมนต์ในโค้ดบอกว่า keep latest); Delta MERGE ไม่มีเงื่อนไข "newer wins" ชำมร่อว
- **ตัวอย่าง (D services/spark/users.csv):** id=2 ซ้ำ → ลบเสีย; แกวไม่มี id → missing_primary_key; id=3 email ว่าง → null_value_in_email

- ผู้กำหนด: PK จาก registry/อนุমান (System); พฤติกรรม Dev; สรีตซ์ duplicate_check.enabled ใน rules ไม่ถูกอ่านโดย engine

(4) จัดการค่าว่าง — PARTIAL

- ทางเลือกค่าเริ่มต้น (Dev): NULL ในคอลัมน์ schema ใดก็ตาม → quarantine null_value_in_<col> (cleansing.py:62-76)
- ทางเติมค่า (User/LLM ผ่าน DSL): fillna, calculate, auto_strategy (SQE:851-883, 1068)
- ตัวอย่างจริง student_course_scores (RC:596-608): กฎ 2 ข้อ fillna score=0 แล้ว calculate score = study_hours*1.5 when score IS NULL เพราะ fillna ทำงานก่อน เงื่อนไข score IS NULL จึงไม่มีวันเป็นจริง → แถวคะแนนว่างกลายเป็น 0 ผ่าน validation และถูกโหลด (ขัดกับ ground truth ใน data/evaluation ที่คำว่า "Missing Score" ต้อง quarantine) — เป็นข้อสรุปจากการอ่าน logic ไม่ได้รัน
- ไม่พบการเติมด้วย mean/median/mode

(5) Standardization — REAL (หลายกลไก ขอบเขตจำกัด)

ชนิด	รายละเอียด	หลักฐาน
วันที่ + พ.ศ.→ค.ศ.	เฉพาะคอลัมน์ชื่อ วันที่ / date / Date; ปี > 2500 → ลบ 543; ผลเป็น string YYYY-MM-DD	standardize.py:6-57
จับคู่คำหลัก→หมวด	standardization_rules ใน registry (ไม่พบตัวที่เขียนคำนี้ใน repo จึงแทบไม่ถูกใช้)	standardize.py:60-103
exact/substring (DSL standardize)		SQE:266-297
Semantic/fuzzy	คะแนน = 0.4-substring + 0.3-token-overlap + 0.3-bigram-cosine; threshold ค่าเริ่มต้น 0.85	S/semantic/similarity.py:35-69 , SQE:382-623
Regex เป็น rule ผู้ใช้	ไม่พบ	NOT FOUND

- ตัวอย่างวันที่ (D grocery_sales.csv, T test_stage_cleansing.py:40-43): 22-7-2569 → 2026-07-22 · 20/07/2026 → 2026-07-20 · 14 Jul 2026 → 2026-07-14
- ข้อจำกัดจากโค้ด: ไม่ตรวจสอบความถูกต้องของปฏิทิน (31-02-2026 → 2026-02-31), ชื่อเดือนที่ไม่รู้จักถูกตีเป็นมกราคม, ไม่รองรับชื่อเดือนภาษาไทย
- Semantic ใน strict mode (ค่าเริ่มต้น) เขียนทับค่าเดิม ไม่มีคอลัมน์สำรอง (SQE:939-941)

(6) Filtering — PARTIAL

DSL filter ตัดแถวใน auto_clean แบบเสียบบ ไม่ quarantine ไม่นับ (SQE:1174-1181)

(7) Aggregation — REAL แต่ไม่ใช้บนข้อมูลธุรกิจ ใน Spark path

- Gold layer: รวมค่าจาก metadata ของ run ใน ES (daily quality, error patterns, financial impact, schema drift) ไม่ใช้ข้อมูลธุรกิจ และเขียนด้วย Python requests (ไม่ใช่ Spark) spark_gold_layer.py:25-29, 184-430
- Dashboard Builder: pandas group-by (sum/avg/min/max/count/count_distinct + time bucket) บน active layer ตามต้องการ — API/dashboard_compute.py
- Whitebox: สถิติรายวิชา/เกรด บน CSV คะแนนนักเรียน whitebox.py:871-944

(8) Join / Merge — PARTIAL

Spark: ไม่พบการ join หลายตารางสำหรับผู้ใช้ (มี broadcast join ภายในสำหรับ semantic mapping และ anti-join หา duplicate; Delta MERGE เป็น upsert ไม่ใช่ join) Whitebox: pd.merge กับตาราง demographics ที่สร้างสังเคราะห์ตอนเริ่มระบบ (whitebox.py:134-153, 1081-1135)

(9) คอลัมน์ที่สร้างขึ้น/คำนวณ — PARTIAL

row_hash, _meta, DSL calculate, คอลัมน์ semantic (<col>_semantic ฯลฯ ใน evolve/enriched mode) พบบั๊กจากการอ่านโค้ด: dry_run ถูกกำหนดเฉพาะในแขน semantic_standardize (SQE:933) แต่ถูกอ่านที่ SQE:1080 — อาจ error แล้วถูก except กลับไว้ (SQE:1171)

(10) แยก Valid/Invalid — REAL

quarantine เก็บคอสมันเดิม + is_invalid, reject_reason, run_id, rejected_at, ingest_id; รันซ้ำ ingest เดิมจะลบแถวเก่าแล้วเขียนใหม่ (assembly.py:36-37, SQE:1704-1711)

(11) Schema evolution — PARTIAL

ตรวจ drift ได้จริงและมี API อนุมัติ แต่ค่าเริ่มต้น require_approval=true (schema.py:180) และ RC ไม่มีบล็อก schema_evolution ทำให้ทุก drift เป็น PENDING อย่างไรก็ตามสถานะ **PENDING ไม่ได้หยุดข้อมูล** คอสมันใหม่ถูกเพิ่มเข้า spec ในหน่วยความจำ (schema.py:146-148) แล้ว Delta autoMerge ทำให้ตาราง active ขยาย schema (SQE:85) ข้อความ "ไม่แก้ registry" หมายถึงไฟล์ registry เท่านั้น การ auto-heal คอสมันที่หายด้วย NULL ทำให้ทุกแถวถูกตีเป็น null_value_in_<col> (ตัวอย่าง: registry ของ users มี age แต่ users.csv ไม่มี)

(12) Outlier — REAL (quarantine ไม่แก้ค่า)

range_rules, IQR, Z-score 3.0, induced rules; value_range.column_overrides ใน RC **ไม่ถูกอ่าน** (ใช้เฉพาะ iqr_multiplier รวม); เมื่อ IQR = 0 ขอบเขตจะหดเป็นจุดเดียวและทุกค่าอื่นถูกตีเป็น outlier (จากการอ่านโค้ด); IQR/Z-score รันกับทุกคอสมันตัวเลข รวมถึงที่เป็น id/ปี

4.2 กฎคุณภาพข้อมูล (Data Quality Rules) — เงื่อนไขจริง

Rule	เงื่อนไขในโค้ด	reject_reason	ฮาร์ดโค้ด/ตั้งค่า
PK ว่าง	PK ใดว่าง (cleansing.py:51-60)	missing_primary_key	Dev (key null_primary_key ใน rules ไม่ถูกอ่าน)
ค่า NULL	คอสมัน schema ที่ไม่ใช่ PK เป็น NULL (:62-76)	null_value_in_<col>	Dev (null_checks ไม่ถูกบังคับใช้)
ชนิดข้อมูล	Integer/Double ที่มีค่าแต่ cast ไม่ได้ (:78-98)	invalid_type_<col>	Dev
วันที่ว่าง	คอสมันวันที่เป็น NULL (:100-109)	missing_date	Dev (null_date_column.enabled=false ถูกเลย)
ซ้ำ	PK ซ้ำ (:130-135)	duplicate_records	Dev
ช่วงค่า	< min หรือ > max (rules.py:6-12)	out_of_range_<col>	User
IQR	นอก [Q1-k*IQR, Q3+k*IQR]	<col>=<val> (expected [lo, hi])	User (mode,k)
Z-score	abs(x-mean)/std > 3.0	<col>_zscore=...	Dev
Induced	OR ของ SQL expression	induced_tree_rule_match	ML + คนอนุมัติ

มิติคุณภาพที่วัดจริง:

มิติ	วัดจริงอย่างไร	บังคับ/แสดงผลเฉยๆ
Completeness	ปฏิเสธแถว NULL; null rate ต่อคอสมันใน profile (profile.py:17-40, tolerance 0.05)	ปฏิเสธ = บังคับ; tolerance = แสดงผล
Uniqueness	ลบซ้ำตาม PK	บังคับ
Validity	cast ชนิด, range, IQR, Z-score	บังคับ
Timeliness	max_lag_hours ต่อรอบ	แสดงผลเท่านั้น (freshness_threshold_hours ถูกบันทึกแต่ไม่ถูกนำมาเทียบ)
Consistency	ไม่พบกฎข้ามฟิลด์/ข้ามตาราง	NOT FOUND
Accuracy	เทียบ ground truth เฉพาะ whitebox benchmark (ข้อมูลนักเรียน)	NOT FOUND ในเส้นหลัก

สูตร **Quality Score**: clean_count / (clean_count + quarantine_count) × 100 (metrics.py:168-175; รับ 0 ถ้าไม่มีข้อมูล) — pass-rate เดียว ไม่นำหนักตามมิติ **Threshold**: ค่าเริ่มต้น 90 ฟัน 70; โหมด adaptive = max(mean(N คะแนนล่าสุด) - stdev, min) (N=15, ต้องมี ≥ 2 รอบ) — dynamic_rules_engine.py:249-335 → ประวัติแยกของตารางหนึ่ง ๆ ทำให้เก็ทชิลดลงได้ (ภายใต้ฟัน) **ผลเมื่อไม่ผ่าน**: critical alert, สถานะ run เป็น warnings แทน success (report.py:75), ไม่ trigger Gold rebuild

4.3 ความครบถ้วนของการ transform เอง

- ไม่มี reconciliation ว่า "แถวเข้า = แถวออก + ถูกปฏิเสธ" ใน Spark path: total_records = ผลรวมของ output (assembly.py:45) ไม่เคยนับแถวนำเข้า แถวที่หายนอกบัญชี: ลบซ้ำใน auto_clean และ DSL filter; ยิ่งกว่านั้น assembly.py:15-33 ห่อการ .count() ของ DF anomaly ด้วย try/except: pass ถ้า count สัมเหลวหลังตัดแถวออกจาก clean แล้ว แถวนั้นจะไม่อยู่ทั้งสองฝั่ง
- ที่มี reconciliation: whitebox — ทุกแถวมีสถานะเดียว (Valid/Review/Quarantine) (whitebox.py:1386-1388)
- สิ่งที่บันทึก: แถว quarantine พร้อมเหตุผล (ระดับแถว), quarantine_breakdown (ต่อเหตุผล), remediation_logs (ข้อความ), stage_seconds, fallback_metrics ของ semantic, drift_details, audit log การแก้ไข
- ไม่บันทึก: จำนวนแถวที่ถูกแก้ไขโดย DSL/cast/standardize แต่ละกฎ, ค่าก่อน-หลังของเซลล์ที่ถูกแก้ (ยกเว้นคอลัมน์สำรอง _raw_col ใน evolve mode)
- Lineage: ระดับตารางเท่านั้น (report.py:61-70) ไม่มี column/step lineage; หน้า lineage inspector มี metadata ฮาร์ดโค้ด (ดูข้อ 6)

ข้อ 5 — Data Loading

5.1 ปลายทางที่เขียนจริง

ปลายทาง	ที่อยู่	รูปแบบ	เนื้อหา	ผู้เขียน
HDFS raw	/data/raw/<table>/<ingest_id>/<table>.csv	CSV	ข้อมูลดิบ	API (WebHDFS) pipeline.py:194-227
HDFS archive	/data/archive/<table>/<ingest_id>	CSV	raw ที่ประมวลผลแล้ว	Spark SQE:1790-1805
HDFS active	/data/active/<table>	Delta Lake	แถว valid	Spark SQE:1713-1735
HDFS quarantine	/data/quarantine/<table>	Delta partitionBy(run_id)	แถว invalid + เหตุผล	Spark SQE:1704-1711
HDFS Reddit	/data/reddit/parquet/subreddit=*	Parquet	โพสต์ Reddit (ไม่มี quality gate)	streaming_job.py:48-55
ES run metadata	sdoqap_quality_runs, sdoqap_lineage_runs, sdoqap_pipeline_runs, sdoqap_runs, sdoqap_run_locks	JSON	จำนวน/คะแนน/พาร/สถานะ	report.py, run_registry.py
ES registries	sdoqap_schema_registry, sdoqap_rules_registry, sdoqap_schema_drifts, sdoqap_schema_proposals, ฯลฯ	JSON	schema, กฎ, drift	engine/API
ES Gold	sdoqap_gold_* (4 index, มี explicit mapping)	JSON	สรุปจาก metadata ของ run	spark_gold_layer.py
ES reddit	index ของ stream	JSON	โพสต์ Reddit	streaming_job.py:62-72

ยืนยันว่าไม่มี (grep หัว repo): _bulk/helpers.bulk, .jdbc(), INSERT INTO, saveAsTable, foreachBatch Postgres เป็นแหล่งเท่านั้น ไม่ใช่ปลายทาง · Grafana ไม่ได้ถูกเขียน (เป็นผู้อ่าน ES) ข้อมูลระดับแถวทั้ง valid และ invalid อยู่ใน Delta บน HDFS เท่านั้น ส่วน Elasticsearch เก็บ metadata/เมตริก/ทะเบียน

5.2 กลไกการเขียน

ด้าน	Active (Delta)	Quarantine (Delta)
โหมด	รอบแรก overwrite; รอบต่อไป MERGE ... whenMatchedUpdateAll().whenNotMatchedInsertAll() ตามเงื่อนไข old.pk = new.pk (SQE:1718-1735)	append (:1710)
Idempotency	key = PK (upsert)	ลบแถวที่ ingest_id เท่ากันก่อนแล้วจึง append — เมื่อมี ingest_id และตารางมีคอลัมน์ ingest_id แล้วเท่านั้น (:1706-1709); เส้นทางเก่า/n8n จะ append ซ้ำหุกรอบ
Retry/backoff	ไม่มี (MERGE สัม → fail-closed ไม่แต่ตาราง :1737-1753)	ไม่มี

ด้าน	Active (Delta)	Quarantine (Delta)
Schema	autoMerge=true (:85)	mergeSchema=true
Maintenance	ทุก 10 เวอร์ชัน OPTIMIZE ZORDER BY (row_hash) + VACUUM 168h (:1756-1761) — ถ้าตารางไม่มีคอลัมน์ row_hash จะ error ถูกกลืน และ VACUUM ไม่ทำงาน (อนุมานจากโค้ด)	—

- **ลำดับสำคัญ:** เขียน **quarantine** ก่อน แล้ว **MERGE active** — สองตารางไม่อยู่ใน transaction เดียวกัน
- **ES:** เขียนที่เอกสาร POST /{index}/_doc timeout 10 วินาที ไม่ retry; ถ้าเขียนล้มเหลวแค่ print แล้วรันต่อ (SQE:96-121) → รันอาจขึ้น SUCCEEDED ทั้งที่ log ลง ES ไม่สำเร็จ แล้ว trust-check จะตอบ "ไม่พบ quality run" → **HALT_INGEST** (lineage.py:367-373)
- **ไม่มี index template** — index ถูกสร้างด้วย dynamic mapping ยกเว้น Gold 4 index; ฟิลด์ quarantine_breakdown/null_profile จะออก mapped field ใหม่ตามชื่อคอลัมน์/เหตุผล

5.3 กันข้อมูลซ้ำและบังคับ schema

ชั้น	กลไก	ข้อจำกัด
ไฟล์	SHA-256 + สถานะ run	ไม่มี atomic claim (อัปโหลดซ้ำพร้อมกันอาจผ่านทั้งคู่); n8k ซ้ำม
ในแบตช์	dropDuplicates(pk) 2 ชั้น	ลำดับแถวที่เก็บไม่รับประกัน; ชั้นแรกไม่ถูกนับ
active	Delta MERGE ตาม PK	ถ้า PK ที่อนุมานซ้ำกันบางส่วน (เกณฑ์ ≥ 90% ไม่ซ้ำ) แถวอาจยุบเจียบ ๆ
ES metadata	_doc ไม่กำหนด id	รันซ้ำ/remediation re-validate เพิ่มเอกสารใหม่ → Gold รวมซ้ำหลายรอบ
Gold	_id กำหนดแน่นอน เขียนทับได้	input อาจถูกนับซ้ำตามข้างบน

Schema: cast เป็นชนิดตาม registry แล้ว validate; ES ไม่บังคับ schema (ยกเว้น Gold); Delta ขนชนิดไม่ได้ → MERGE ล้ม → fail-closed

5.4 Quality gate ก่อนโหลด — อธิบายให้ชัด

- **ระดับแถว:** มีจริง — แถวที่ไม่ผ่าน validation/dedup/range/anomaly ถูกแยกไป quarantine ก่อน เขียน
- **ระดับตาราง:** **ไม่มี gate ก่อนโหลด** — quality_score เป็น stage POST_LOAD (plan.py) คำนวณหลัง quarantine append และ active MERGE (SQE:1704-1735 แล้วจึง :1774) ตารางที่คะแนน 0% ยังโหลดแถว valid ที่มีเข้า active
- **gate ที่มีจริงฝั่งผู้บริโภค:** GET /api/v1/lineage/{table}/trust-check (lineage.py:340-447) ให้ is_safe_to_consume = score ≥ threshold และไม่มี schema proposal ค้าง; ไม่พบ run → **HALT_INGEST** — เป็น advisory (ผู้เรียกเลือกใช้เอง)
- **เงื่อนไขที่ยกเลิกก่อนโหลดได้:** ไฟล์ว่าง (exit 75/SKIPPED), lock ขนกัน (SKIPPED), PK ที่ลงทะเบียนไว้ขาดในหัวไฟล์ (API 400), strict_csv_guard (ไม่มีใครตั้ง)

5.5 ตรวจหลังโหลด

รายการ	สถานะ
Delta commit สำเร็จ	จับ exception เฉพาะ MERGE
อ่านกลับ active/quarantine	มี แต่ใช้คำนวณ metrics (distribution/freshness/breakdown) ไม่ได้เทียบกับ clean_count/quarantine_count
นับ Spark vs ES/Delta ปลายทาง	NOT FOUND
จัดการ failed item ของ ES	NOT FOUND (ไม่มี bulk)
Run ID / ingest ID / สถานะ	REAL (SUCCEEDED = exit code 0 ไม่ได้สะท้อนคุณภาพหรือผล log ลง ES)
Lineage	ระดับตารางเท่านั้น
Rollback / Delta time-travel	NOT FOUND

รายการ	สถานะ
Staging แล้ว rename เข้า active	NOT FOUND (staging_path ประกาศแต่ไม่ใช่ SQE:1625)

5.6 ชนิดของ Loading

ชนิด	มีจริงไหม
Batch ต่อ ingest	REAL
Full load เข้าตามรอบ	REAL (n8n ทุก 30 นาทีส่งทั้งแหล่ง; ingest/api ดาวน์โหลดทั้งชุด)
Incremental ฝั่งต้นทาง (watermark/CDC)	NOT FOUND
Incremental ฝั่งปลายทาง (upsert)	REAL (Delta MERGE)
Streaming	PARTIAL (Reddit เท่านั้น, จำกัดเวลา, ไม่มี gate/quarantine/registry)
Micro-batch สำหรับ pipeline หลัก	NOT FOUND (ข้อความ "Micro-batch Streaming" ใน lineage.py:261 เป็นฮาร์ดโค้ด)

5.7 เมื่อเกิดข้อผิดพลาด

กรณี	การจัดการ	สิ่งที่ผู้ใช้เห็น
อ่าน/ALIGN ล้ม	เขียน sdogap_pipeline_runs failed, ปลอม lock, exit 1	"ตรวจไม่สำเร็จ"
MERGE ล้ม	[CRITICAL] , บันทึก failure "active table left untouched", ไม่ fallback เป็น overwrite	FAILED
POST_LOAD ล้ม	exception ไม่ถูกจับ (lock ปลอมโดย lock_protector) — ข้อมูลโหลดไปแล้ว แต่ raw ไม่ถูก archive	UI แสดงลั้มเหลวทั้งที่ข้อมูลเข้าแล้ว
ES metadata ล้ม	print อย่างเดียว	ยัง SUCCEEDED
Lock ถูกไขอยู่	SKIPPED (exit 75)	"ข้าม เพราะมีรอบอื่นกำลังใช้ตารางนี้"
สถานะ run ใน UI	แสดงป้ายสถานะ ไม่แสดงจำนวนแถวหรือข้อความ error (RunStatusLine.jsx)	

ไม่มีตัวกั run ที่ค้าง RUNNING/QUEUED (queue อยู่ในหน่วยความจำ daemon รีสตาร์ทแล้ว QUEUED ค้างและยังบล็อกการอัปโหลดซ้ำ)

5.8 Flow จริง

```
ข้อมูลหลัง transform (Spark)
├─ แยกระดับแถว: Valid / Invalid (Dev rules)
├─ Invalid → ลบแถวของ ingest_id เดิม → append → Delta /data/quarantine [ทำก่อน]
├─ Valid → MERGE (PK) → Delta /data/active ; ล้มเหลว = fail-closed
├─ POST_LOAD: คัด quality_score หลังโหลด → alert / state=warnings / ตัดสิน Gold (ไม่ขวางโหลด)
├─ เขียน ES: quality_runs · lineage_runs · pipeline_runs
├─ ถ้า score ≥ threshold: spawn Gold rebuild (subprocess ไม่ตรวจผล)
├─ archive raw ; ปลอม lock
├─ daemon: ถ้า quarantine > 0 → auto-remediation (LLM) → รีเข้า ingest เดิม (1 รอบ/ตาราง)
```

ข้อ 6 — การใช้ประโยชน์จากข้อมูล

6.1 หน้า UI และสิ่งที่แต่ละหน้าทำจริง (App.jsx:99-112)

Route	หน้า	ทำอะไร / API ที่เรียก	สถานะ
/	Home	สถานะบริการ (/services/status), KPI (/kpi/stats), badge proposal	REAL (badge นับตัวอย่าง 3 รายการเมื่อ ES ว่าง)
/ingestion	Ingestion	ingest ไฟล์/DB จริง; แห็บ API/Stream จำลอง	REAL / UI ONLY
/rules	Rules Config	CRUD กฎ, AI proposal (สร้าง/อนุมัติ/ปฏิเสธ), ตั้งค่า Groq	REAL (มีป้าย "ตัวอย่าง")
/pipeline	Jobs & Pipelines	ดู run, retry, rebuild Gold, benchmark	REAL
/export	Workspace Exports	preview/ดาวน์โหลด CSV (active/quarantine/raw/gold), banner trust-check	REAL (มีค่า fallback 9400/100/600/93.1)
/dashboard	Dashboards (4 แห็บ)	Executive, Business Impact, Data Quality, Technical	PARTIAL (ปะข้อมูลจริงกับ MOCK)
/dashboard-builder	Create Dashboard (AI)	ดูข้อ 6.2	REAL
/analytics	Query & Metrics	projection, clustering, impact, recommendations	PARTIAL
/schema	Catalog	อนุมัติ/ปฏิเสธการเปลี่ยน schema	REAL
/whitebox	Audit Trail	pandas pipeline บนชุดคะแนนนักเรียน	REAL (ข้อมูลตายตัว)

6.2 Create Dashboard (AI) แบบ end-to-end — REAL

```
UI (DashboardBuilder.jsx)  4 ชั้น: เลือก dataset → ดูตัวอย่าง → เขียนความต้องการ+กลุ่มผู้ชม → แดชบอร์ด
① GET /dashboards/datasets      dashboards.py:73   รายการจาก /data/active (Delta ที่ผ่าน gate แล้ว) + dataset เสมือน _quality_runs
② GET /datasets/{t}/preview     profile + 20 แถว
③ โหลดตารางทั้งก่อนเข้า API ผ่าน WebHDFS+pandas (cache 120 วินาที, ไม่เกิน 4 เฟรม) dashboard_data.py:157-171
④ POST /generate                dashboards.py:85
    dashboard_llm.generate_spec() → Groq (openai/gpt-oss-120b, temp 0.2, timeout 20 วินาที, retry 1 ครั้ง)
    ส่งเฉพาะ: ชื่อ dataset, ความต้องการ, profile (ชื่อคอลัมน์, ชนิด, distinct, missing%, min/max ตัวเลข/วันที่)
    ไม่ส่ง: แถวข้อมูลและค่าหมวดหมู่ใด ๆ ; คอลัมน์ที่ดูเป็น identifier จะไม่ส่ง min/max
    ถ้าไม่มี key/ส่ม/spec ไม่ผ่าน → fallback_spec() แบบกฎจัดโน้ต
⑤ validate_spec() dashboard_spec.py:191  whitelist ชนิด widget/aggregation/time grain, จำกัด 16 widget/6 filter, ตัดคอลัมน์ที่ไม่มีจริง
⑥ compute_dashboard() dashboard_compute.py:211  pandas คำนวณ KPI/bar/line/area/pie/table – LLM ไม่ได้สร้างตัวเลข
⑦ แสดงผล DashboardCanvas (grid 12 คอลัมน์) + Recharts
⑧ ได้ตอบ POST /render (กรอง/คลิกกราฟ drill), POST /refine (สั่งแก้ด้วย LLM, ได้รายการ changes, สูงสุด 50 ครั้ง)
⑨ บันทึก POST/PUT /saved → ES sdoqap_dashboards (เก็บ spec ไม่ใช่ตัวเลข; เปิดซ้ำจะ render ใหม่ จึงสดตามข้อมูลปัจจุบัน)
```

ผู้ใช้ตรวจสอบผลได้อย่างไร: ตัวนับ rows_after_filter / rows_total, ตัวอย่าง 20 แถวในขั้นที่ 2, widget ตารางที่แสดงแถวจริงและ total_rows, แบนเนอร์บอกว่าใช้ groq (<model>) หรือ rules พร้อม warnings ของ widget ที่ถูกตัด, และเทียบกับ CSV จาก /export/active/{table} **มี test** ฝั่ง API 8 ไฟล์ (services/api/tests/test_dashboard_*.py, test_dashboards_*.py) และ UI 3 ไฟล์ (ยังไม่ได้รัน) **ข้อจำกัด:** โหลดทั้งตารางเข้าหน่วยความจำ API ไม่มี cap จำนวนแถว (API memory limit 2G); refine ต้องใช้ LLM (ไม่มี fallback); แดชบอร์ดที่บันทึกใช้ร่วมกันได้ทุกผู้ใช้ที่ล็อกอิน (ไม่มี permission รายแดชบอร์ด)

6.3 รายการตามทีถามทีละหัวข้อ

Dashboard

- **Grafana — PARTIAL:** มี datasource SDOQAP_Elasticsearch (infra/grafana/provisioning/datasources/elasticsearch.yaml) และ alert rules เท่านั้น ไม่มี dashboard JSON/provider UI ไม่ลิงก์ไป Grafana (grep grafana|iframe|kibana|prometheus ใน services/ui/src ไม่พบ) ผู้ใช้ต้องสร้าง panel เองใน Grafana (admin/admin ใน compose)
- หน้า /dashboard — **PARTIAL:** ดูข้อ 6.4
- **Create Dashboard (AI) — REAL**

KPI — REAL (บางตัวติดป้ายผิด)

- แหล่ง: sdoqap_quality_runs, sdoqap_pipeline_runs, sdoqap_schema_drifts ผ่าน /kpi/stats และ /executive/overview (analytics.py:12-377)
- ที่คำนวณจริง: Data Health Score (เกณฑ์ 95/88), Pipeline SLA availability (สัดส่วน run ที่ไม่ล้มเหลว), freshness (สัดส่วน lag ≤ 1 ชม.), COPDQ (analytics.py:673-766)
- ข้อควรรู้: mtt_d_minutes คือเวลา pipeline เฉลี่ย ไม่ใช่เวลาตรวจพบปัญหา; การ์ด **Sell-In/Out Gap เป็น MOCK**; การ์ด Completeness/Validity อาจใกล้ 0 เพราะ key ใน data_quality_breakdown (null_primary_key, missing_values, invalid_type...) ไม่ตรงกับเหตุผลจริงที่ engine เขียน (missing_primary_key, null_value_in_col, invalid_type_col) มีเพียง duplicate_records ที่ตรง (อนุมานจากโค้ด); การ์ด "Consistency" แสดงคะแนนสุขภาพพร้อมทั้งข้อความตายตัว "Cross-table checks OK" (Dashboard.jsx:1181)
- COPDQ มี 2 โมเดลต้นทุนที่ไม่ตรงกัน: analytics.py:704-721 (\$2/แถว, rows×0.05×50, risk ตาม drift) กับ Gold (\$11/แถว ฮาร์ดโค้ด spark_gold_layer.py:48)

Data Visualization

ที่	กราฟ	ข้อมูล	จริงหรือไม่
Builder	bar/line/area/pie/donut/KPI/table (Recharts)	pandas บนตารางที่เลือก	REAL
Dashboard Executive	SLA bars + area trend	/anomaly/sources (ค่า quality_score ล่าสุด 12 รายการ)	PARTIAL: แกนเวลาถูกสร้างขึ้น now - (11-i)×10 นาที ไม่ใช่เวลา run จริง (analytics.py:383-387)
Dashboard Business	Sell-In vs Sell-Out	/analytics/sell-in-out	MOCK (timeline 7 วันฮาร์ดโค้ด analytics.py:799-807; โค้ดมี TODO และ is_example: True)
Dashboard Data Quality	leaderboard + การ์ดมิติ	/quality?limit=50	REAL (มีข้อควรระวังเรื่อง key ข้างบน)
Dashboard Technical	ECharts lineage graph	run ที่เลือก / whitebox/state	PARTIAL (จำนวนจริง แต่มีค่าตั้งต้น 10100/600/93.1 และโดนดัดแปลง)
Analytics	forecast + confidence band	/analytics/projection	PARTIAL: วัน 1–7 จาก regression, วัน 8+ ขยายต่อฝั่งเบราร์เซอร์ (หน้าเว็บแจ้งไว้)
Analytics	error clusters	/analytics/clustering	PARTIAL (จับคีย์เวิร์ดแล้วตั้งชื่อ source เช่น "Database Sync" เป็นการเดา)

Data Analytics — PARTIAL

- Projection: linear regression ของ quality_score 10 ค่าล่าสุด, band โตตาม horizon, Stability Index 100–4σ, ความน่าจะเป็นฝ่าฝืน SLA ด้วย normal CDF (analytics.py:460-597)
- Clustering: รวม quarantine_breakdown แล้ว map substring → ชื่อกลุ่ม (analytics.py:599-671)
- Whitebox downstream: pass rate, เกรด, ช่วงคะแนน, benchmark precision/recall/F1 เทียบ ground_truth.csv (whitebox.py:740-944)
- Gold: เป็นข้อมูลสรุปของ metadata ไม่มีกราฟใดใช้ ใช้ในตารางพริ้ว/ CSV ของหน้า Export เท่านั้น และ rebuild ต้องกดปุ่ม/trigger หลังรันผ่าน (ไม่มี schedule)

Business Insight — PARTIAL

/executive/overview (analytics.py:166-307) ผสมตัวเลขจริง (จำนวน quarantine/drift/run ล้มเหลว, COPDQ) กับข้อความและระยะเวลาฮาร์ดโค้ด เช่น "รายงานผู้บริหารรอบเช้าล่าช้า 25 นาที", ระยะเวลาปัญหา "24 mins/45 mins/1 hr 12 mins", แถว "Duplicate Transactions" ที่เป็น Normal/Resolved เสมอ และการจับคู่ business area กับชื่อ dataset users / grocery_sales / products

Monitoring — PARTIAL

- จริง: feed กิจกรรมรวม 3 index (system.py:212-288), probe พอร์ต 11 บริการ (system.py:42-84), CPU/Mem จาก /proc
- /performance/metrics สร้างประวัติ CPU/Mem สังเคราะห์ และไม่มีหน้าใดเรียก
- Prometheus มีไฟล์ config (infra/prometheus/prometheus.yml) แต่ ไม่มี service ใน compose/swarm และ Grafana ไม่มี Prometheus datasource → ไม่ได้ deploy

Data Quality Monitoring และ Alert — PARTIAL

ช่องทาง	เงื่อนไข	ส่งออก	สถานะ
Spark engine	score < threshold, Z-score อัตรา quarantine > 3.0, schema drift	send_n8n_alert → alert_router + n8n webhook	REAL ในโค้ด; ส่งถึงปลายทางต้องตั้ง SLACK_WEBHOOK_URL / LINE_NOTIFY_TOKEN ซึ่ง .env.example ไม่ได้ระบุ (ไม่ตั้ง = พิมพ์ log เท่านั้น alert_router.py:83-88)
n8n polling	ทุก 15 นาที: quarantine > 0 หรือ score ต่ำกว่าเกณฑ์	POST /system/alert	PARTIAL: compose ไม่ได้ import workflow ให้ ต้อง import เอง
Grafana rules	quality_score < 80; quarantined_records > 0 เฉลี่ย > 20	webhook → /system/alert	PARTIAL: กฎที่ 2 ข้อความบอก "20% ของ records" แต่คำนวณเฉลี่ยจำนวน ไม่ใช่ข้อตรวจ; ไม่ยืนยันว่า Grafana ยอมรับ rule model/uid ตรงกัน
trust-check API	score ≥ threshold และไม่มี proposal ค้าง	JSON SAFE/WARNING_SUSPECT/HALT_INGEST	REAL

Recommendation

- /analytics/recommendations (analytics.py:833-891): กฎตายตัว 3 แบบ (NOTIFY_DEV , HALT_INGEST , RESTORE_BACKUP) หน้าเว็บระบุว่า "ไม่ใช่คำแนะนำจากโมเดล AI" — ข้อความ REAL
- ปุ่ม "นำไปใช้" — UI ONLY: แดเช็ต state + toast แล้ว POST /whitebox/state {confirm_rules:true} ซึ่ง backend เก็บแค่เวลา confirmed_at (Analytics.jsx:32-41 , whitebox.py:1471) ไม่มี endpoint ที่ halt/แจ้ง dev/restore จริง
- AI rule proposals + remediation tickets: REAL และมีคนอนุมัติ; ถ้า ES ไม่มีข้อมูลจะแสดงตัวอย่าง 3 รายการที่มี is_example (อนุมัติแล้วไม่เปลี่ยนอะไร); โครงสร้าง rule จาก LLM ไม่ตรงกับที่ขั้นตอนมิติ merge (ต้องมี rule_path) จึงอนุมัติแล้วอาจไม่มีผลต่อ rules_config.json (promoted_count = 0)

AI / LLM — ใช้ที่ไหน ส่วนไหน LLM ส่วนไหนกฎตายตัว

ฟีเจอร์	โมเดล	ส่งอะไรให้ LLM	ส่วนที่ไม่ใช่ LLM / guard
Dashboard builder (generate/refine)	Groq openai/gpt-oss-120b (หรือค่าที่บันทึกไว้)	profile คอลัมน์ + ข้อความผู้ใช้ (ไม่มีแถว/ค่าหมวดหมู่)	validate/layout/คำนวณ/diff/fallback ทั้งหมดเป็นโค้ด
AI context บน Dashboard	Groq (model หารัดโค้ด, timeout 12 วินาที)	ข้อความข้อเท็จจริงที่คำนวณจากกฎ	ข้อความหลักเป็นกฎ; LLM เรียบเรียง 7 ศัพท์; มีป้าย "โดย AI" เมื่อสร้างจริง (whitebox.py:1774-1856)
AI rule advisor (ใน Spark)	Groq → Ollama qwen2.5:3b → heuristic	ตัวอย่าง quarantine ≤ 20 แถว (ปิดบังคับคอลัมน์ที่เป็น identifier)	ผลเป็น PROPOSED ต้องมีคนอนุมัติ; decision tree เป็น Spark ML ไม่ใช่ LLM
Auto-remediation	Ollama → Groq	ตัวอย่าง quarantine 5 แถว ไม่มีการปิดบัง (รวมถึงตอน fallback ไป Groq cloud)	บังคับใช้เมื่อ confidence ≥ 0.80 โดยไม่ต้องมีคนอนุมัติ
Alert, anomaly, forecast, COPDQ	ไม่ใช่ LLM	—	Z-score, linear regression, keyword clustering

หมายเหตุ: Ollama ผูกกับ compose profile ai และไม่พบสคริปต์ที่ pull โมเดล qwen2.5:3b (ถ้ายังไม่ pull ระบบจะตกไป heuristic — ยังไม่ได้ยืนยันตอนรัน)

Decision Support — การกระทำที่ทำได้จริง

trust-check API · ดาวน์โหลด CSV (clean/quarantine/gold) · อนุมัติ/ปฏิเสธ schema drift และ AI rule · resolve ticket · retry run · แก้กฎ · บันทึกแดชบอร์ด · review รายแถวใน whitebox ส่วนที่เป็นประมาณการ: ตัวเลข COPDQ (ค่าคงที่สมมติ), forecast (regression ≤ 10 จุด), คะแนนสุขภาพรายพื้นที่ธุรกิจ

6.4 REAL เทียบกับ UI ONLY / MOCK (เช็คลิสต์)

รายการ	ที่อยู่	ประเภท
Sell-In vs Sell-Out timeline + ยอดสรุป	analytics.py:776-831 (สำเนาใน Dashboard.jsx:79-97)	MOCK
การ์ด KPI "Sell-In/Out Volume Gap" (ไม่มีป้ายตัวอย่าง)	Dashboard.jsx ส่วน hero	MOCK ที่แสดงเป็น KPI
narrative/ระยะเวลาปัญหาของ business insight	analytics.py:176-301	MOCK/ชาร์ตโค้ด
แกนเวลาของกราฟ anomaly	analytics.py:383-387	สร้างขึ้น
ปุ่ม "นำไปใช้" ของ recommendation	Analytics.jsx:32-41	UI ONLY
AI proposal ตัวอย่าง 3 รายการ	dynamic_rules.py:383-420	MOCK (มีป้าย)
ค่าสำรอง 9400/100/600/93.1	DataExport.jsx:77-80, EchartsDataLineage.jsx:9-12	ชาร์ตโค้ด
"Consistency: Cross-table checks OK"	Dashboard.jsx:1181	ข้อความล้วน
metadata ของ lineage node (Spark 14.8 วินาที, "2 Workers 4 Cores 8GB", n8n 1.0.5, prod-db-replica, "Parquet/Snappy", "JSON-Lines/Gzip", CDC)	lineage.py:156-301	MOCK (ของจริงคือ CSV + Delta)
/performance/metrics	system.py:174-177	MOCK (ไม่มี UI เรียก)
Grafana dashboards / Prometheus ที่รัน	—	NOT FOUND
n8n workflow import จัดโน้ต / ตัวแปร Slack-LINE	—	NOT FOUND
backend ของ HALT_INGEST/NOTIFY_DEV/RESTORE_BACKUP	—	NOT FOUND
seed_es.py ข้อมูลสังเคราะห์	services/api/seed_es.py	MOCK (รันเมื่อเท่านั้น)

ข้อสังเกตด้านการเข้าถึงข้อมูล: route /export/active|quarantine|raw/{table}, /export/gold/*, /quality, /analytics/*, /gold/* ไม่พบ dependency require_session (เฉพาะ /dashboards/*, /export/records, และ endpoint ที่เขียนเท่านั้นที่ต้องล็อกอิน) — ควรรู้ไว้เพื่ออาจารย์ถามเรื่องความปลอดภัย

7. System Actual Workflow (จากโค้ดจริงทั้งระบบ)

ตัวย่อผู้ทำงาน: **U**=User · **API**=FastAPI · **n8n** · **D**=Spark trigger daemon · **S**=Spark engine · **Dev**=กฎชาร์ตโค้ด · **LLM**

```
[แหล่งข้อมูล] CSV/Excel (U) · REST API (U/n8n) · PostgreSQL (U/n8n) · [n8n schedule ทุก 30 นาที: แหล่งตายตัว]
|
▼ EXTRACTION / INGESTION (ข้อ 3)
API ตรวจ auth · ชื่อตาราง · ขนาด ≤200MB · ไฟล์ว่าง · SSRF/SQL guard · SHA-256 ซ้ำ · PK ในหัวไฟล์ [Dev]
API แปลง Excel/JSON/DB → CSV → เขียน raw → HDFS /data/raw/<table>/<ingest_id>/ (retry 5)
API สร้าง sdoqap_runs (QUEUED) → เรียก daemon /retry
|
▼ ORCHESTRATION
D คิว FIFO ต่อ 1 ตาราง → spark-submit → state RUNNING
S ขอ lock ใน ES (heartbeat 60 วินาที, fail-closed)
|
▼ TRANSFORMATION + VALIDATION (ข้อ 4)
S อ่าน raw เป็น string → [ALIGN] schema_align
S [TRANSFORM] schema_drift → auto_clean (DSL ที่ User/LLM กำหนด + ลวนซ้ำ) → validation → dedup
→ standardize_dates → standardize_categories → range_rules → anomaly_iqr → anomaly_zscore → anomaly_induced
S แยก Valid / Invalid (ระดับแถว) → quarantine_assembly → column_filter
|
▼ LOADING (ข้อ 5)
S Invalid → Delta /data/quarantine (ลบ ingest_id เดิมก่อน)
S Valid → Delta MERGE ตาม PK → /data/active
|
▼ DATA QUALITY (หลังโหลด)
S [POST_LOAD] distribution · quarantine_breakdown · copdq · freshness · quality_score · ai_advisory[LLM] · operational_impact · report
S เขียน ES: quality_runs · lineage_runs · pipeline_runs → alert ถ้า score < threshold / drift
S ถ้า score ≥ threshold → rebuild Gold (metadata aggregates → ES sdoqap_gold_*)
S archive raw → /data/archive ; ปลอย lock
D ถ้า quarantine > 0 → auto_remediation [LLM สร้างกฎ, confidence ≥ 0.80] → รันซ้ำ ingest เดิม (1 รอบ) ; อัปเดต state SUCCEEDED/FAILED/SKIPPED
|
▼ UTILIZATION (ข้อ 6)
U Create Dashboard (AI): API อ่าน Delta active → LLM ออกแบบ spec → pandas คำนวณ → ES sdoqap_dashboards
U Export CSV · trust-check · Dashboards/Analytics (ES metrics) · อนุมัติ schema/rule · retry · แก้กฎ
Grafana อ่าน ES (มีแค่ datasource + alert rules; ไม่มี dashboard)

[เส้นแยก] Reddit: U → API → D → Kafka → Spark Streaming → Parquet + ES (ไม่เข้า quality engine)
```

ใครทำอะไร: - **Dev** — กฎ validation, ลำดับ stage, สูตรคะแนน, SSRF/SQL guard - **User** — อัปโหลด/ส่ง ingest, ตั้งกฎ (range_checks, value_range, DSL), อนุมัติ schema/rule/proposal, สร้างและบันทึกแดชบอร์ด - **System/Spark** — อนุมัติ schema+PK, drift, anomaly, MERGE, คำนวณ metrics - **LLM** — ออกแบบ dashboard spec (ต้องผ่าน validation), เสนอกฎ (advisor, ต้องมีคนอนุมัติ), สร้างกฎ remediation (บังคับใช้อัตโนมัติ), เรียบเรียงข้อความ AI context - **n8n** — ตั้งเวลา ingest แหล่งตายตัว, relay webhook, ส่ง alert (ต้อง import workflow เอง)

8. จุดที่เอกสาร/UI ในโปรเจกต์พูดไม่ตรงกับโค้ด (เพื่ออาจารย์ถาม)

ที่	ข้อความ/ที่มา	ความจริงในโค้ด
README.md:230	host ว่างหมายถึงอนุญาตทุก host	โค้ด fail-closed: ไม่ตั้ง API_INGEST_ALLOWED_HOSTS อนุญาตเฉพาะ data.go.th (ingest_guards.py:23-37)
UI แท็บ API / Stream	ดูเหมือน ingest จริง	เรียก endpoint จำลอง ช่อง broker/topic/group ไม่มีผล
Home "Kafka Ingesting"	ดูเหมือนมีข้อมูลไหล	เป็นผลเช็ค TCP port
docs/presentation/03-rubric-scorecard.md:84	"ยอดตรงกัน 10,000 = 9,370 + 630" เป็นหลักฐานความครบถ้วน	total = clean + quarantine เสมอ (assembly.py:45) พิสูจน์ความสอดคล้องภายใน ไม่ได้เทียบต้นทาง (docs เองก็ระบุช่องว่าง 100 แถว)
docs/presentation/03-rubric-scorecard.md:145 (FR-09)	เขียน staging แล้ว rename เข้า active	ไม่ได้ทำ ใช้ Delta MERGE
docs/presentation/01-system-explainer.md:108	Idempotent: รันซ้ำแล้วเท่าเดิม	จริงสำหรับ active ตาม PK; ไม่จริงสำหรับ quarantine เส้นเก่า/n8n, ES metadata, ยอดรวม Gold
docs/architecture/data_flow.md	Great Expectations, dbt, Airflow	ไม่พบในโค้ด/compose

ที่	ข้อความ/ที่มา	ความจริงในโค้ด
docs/architecture/*	quarantine เป็น HDFS CSV	เขียนเป็น Delta
docs/architecture/schema_drift_governance.md	gate ตามคะแนนความรุนแรง ≤ 4	gate จริง = ทุกการเปลี่ยนเป็นคอลัมน์ใหม่ + policy (schema.py:174-190)
ConfigGuide.jsx:203-217	แจ้งเตือนทันทีเมื่อ null เกิน tolerance	engine ปฏิเสธทุก NULL และไม่มี alert tolerance (null_checks แค่ profile)
ConfigGuide.jsx:245,483	value_range mode auto/manual และ iqr ต่อคอลัมน์	รันเฉพาะ auto / adaptive ; override ต่อคอลัมน์ไม่ถูกอ่าน
schema.py:67	"12.00" ไม่กลายเป็น null	regex ทำให้กลายเป็น 1200 (จากการอ่านโค้ด)
cleansing.py:129	เก็บแถวล่าสุด	ไม่รับประกันด้วย dropDuplicates หลัง orderBy
rules_config.json พิลด์ ai_advisor.model	ระบุโมเดล	ถูกละเลย (อ่านจาก ES settings/env)
scripts/tests/test_ingest.py	ทดสอบ ingest	payload/route/ตารางไม่ตรง workflow จึงผ่านไม่ได้ตามที่เขียน

9. สิ่งที่ยังไม่ได้ยืนยัน (ต้องรันระบบจริง)

- พฤติกรรมตอนรัน Spark/Delta/ES ทั้งหมด (เอกสารนี้อ่านจากโค้ด)
- Spark ตัด UTF-8 BOM ที่หัวคอลัมน์แรกหรือไม่
- ค่า default page size ของ CKAN เมื่อไม่ส่ง limit
- OPTIMIZE ZORDER ล้มเหลวกับตารางที่ไม่มี row_hash จริงหรือไม่
- retention ลบไฟล์เดอร์ partition ของ Delta quarantine แล้วทั้ง reference ค้างใน _delta_log หรือไม่
- Grafana ยอมรับ alert rules และ datasourceId ตรงกันหรือไม่
- Ollama pull โมเดลแล้วหรือยัง; Groq/Slack/LINE เข้าถึงได้หรือไม่
- ผลของ unit/integration test (ไม่ได้รัน)

ไม่มีการให้คะแนนในเอกสารนี้ ตามที่ผู้ใช้กำหนด